

多智能体系统的局部分类误差实验方案

Agent 数量与通信轮数对 MAS 局部 Error Rate 的影响

Agent Expressional Graph

2026 年 4 月 21 日

核心设定

本实验把每个 agent 的局部 error rate 定义为：该 agent 在自己的本地数组 shard 上，对每个样本做分类预测后，与本地数组对应的真实类别逐项比较得到的错误比例。实验控制 agent 数量

$$N \in \{2, 4, 8, 16, 32, \dots\}$$

并观察 MAS 运行若干通信轮后的误差变化，例如

$$R \in \{2, 3, 5\}.$$

重点问题是：随着 agent 数量增加、通信轮数增加，局部分类误差是否下降，下降速度是否取决于通信拓扑，以及误差是否在 agents 之间变得更均匀。

1 实验目标

设一个全局分类任务被切分给多个 agents。每个 agent 只直接观测自己的本地数组 shard，并在多轮通信中接收邻居 agents 的消息。实验希望回答三个问题：

- 局部性能**：每个 agent 在自己 shard 上的分类 error rate 如何随通信轮数下降？
- 规模效应**：当 agent 数量从 2, 4, 8, 16, ... 增加时，MAS 的平均误差、最差误差和误差方差如何变化？
- 通信效应**：固定任务和 agent 数量时，更多通信轮数 $R = 2, 3, 5$ 是否带来稳定收益？

2 符号与数据切分

全局数据集记为

$$\mathcal{D} = \{(x_m, y_m)\}_{m=1}^M,$$

其中 x_m 是数组中的第 m 个样本或元素， $y_m \in \{1, \dots, K\}$ 是该样本的真实类别。将 $\mathcal{D}$ 划分为 N 个不重叠 shard：

$$\mathcal{D} = \bigcup_{i=1}^N \mathcal{D}_i, \quad \mathcal{D}_i \cap \mathcal{D}_j = \emptyset \quad (i \neq j).$$

第 i 个 agent 只直接看到自己的局部数组：

$$\mathcal{D}_i = \{(x_{ij}, y_{ij})\}_{j=1}^{n_i},$$

其中 $n_i = |\mathcal{D}_i|$ 。真实标签 y_{ij} 只用于评估，不应泄露给需要盲测的 LLM agent。

表 1: 主要实验变量

符号	含义
N	agent 数量, 推荐 sweep 为 $\{2, 4, 8, 16, 32, \dots\}$
R	MAS 通信轮数, 推荐 sweep 为 $\{2, 3, 5\}$
K	分类类别数
$\mathcal{D}_i$	第 i 个 agent 的本地数组 shard
n_i	第 i 个 shard 的样本数
$\hat{y}_{ij}^{(r)}$	第 r 轮后 agent i 对本地样本 x_{ij} 的预测类别
$e_i^{(r)}$	第 r 轮后 agent i 的局部分类错误率

3 局部 Error Rate 的定义

在第 r 轮通信结束后，第 i 个 agent 对自己的本地数组输出预测标签：

$$\hat{\mathbf{y}}_i^{(r)} = (\hat{y}_{i1}^{(r)}, \hat{y}_{i2}^{(r)}, \dots, \hat{y}_{in_i}^{(r)}).$$

逐样本分类错误定义为

$$\ell_{ij}^{(r)} = \mathbf{1}[\hat{y}_{ij}^{(r)} \neq y_{ij}],$$

其中 $\mathbf{1}[\cdot]$ 是指示函数。于是，第 i 个 agent 的局部 error rate 为

$$e_i^{(r)} = \frac{1}{n_i} \sum_{j=1}^{n_i} \mathbf{1}[\hat{y}_{ij}^{(r)} \neq y_{ij}]$$

解释

这个定义只比较 agent 自己本地数组上的分类结果，不要求 agent 对全局数组给出完整预测。因此它能直接衡量：通信是否帮助每个 agent 改善自身局部判断。

如果 agent 输出的是类别概率 $p_i^{(r)}(y | x_{ij})$ ，则先取最大概率类别：

$$\hat{y}_{ij}^{(r)} = \arg \max_{c \in \{1, \dots, K\}} p_i^{(r)}(c | x_{ij}).$$

如果系统只保存了局部混淆矩阵 $C_i^{(r)}$ ，也可以等价计算：

$$e_i^{(r)} = 1 - \frac{\text{tr}(C_i^{(r)})}{n_i}.$$

4 MAS 运行设置

每次实验由三组核心条件确定：

$$(N, R, \tau),$$

其中 N 是 agent 数量, R 是通信轮数, τ 是通信拓扑或邻居可见性策略。推荐的最小实验矩阵如下：

表 2: 推荐实验 sweep

因素	推荐取值	目的
Agent 数量 N	2, 4, 8, 16, 32	观察规模效应
通信轮数 R	2, 3, 5	观察早期通信收益
Topology τ	chain, mesh, star, one-peer exponential	比较信息传播结构
随机种子	至少 5 个 seeds	降低单次运行偶然性

第 r 轮的同步 MAS 更新过程为：

1. 每个 agent a_i 从自己的局部数组 $\mathcal{D}_i$ 形成初始预测或 belief state。
2. 根据 topology τ 计算第 r 轮 agent a_i 能读取的邻居集合 $\mathcal{N}_i^{(r)}$ 。
3. 每个 agent 接收邻居上一轮的结构化消息或 belief state。
4. agent 更新自己的预测 $\hat{\mathbf{y}}_i^{(r)}$ 。
5. 评估器在本地 shard 上计算 $e_i^{(r)}$ ，但不把真实标签反馈给 agent。

5 聚合指标

为了同时观察整体趋势和 agent 间不均衡，建议记录以下指标。

5.1 样本加权平均误差

当各 shard 大小可能不同，主报告指标使用样本加权平均：

$$E_{\text{weighted}}^{(r)} = \frac{\sum_{i=1}^N n_i e_i^{(r)}}{\sum_{i=1}^N n_i}$$

它等价于所有本地样本合并后的总体分类错误率。

5.2 Agent 平均误差

如果关注每个 agent 作为一个独立决策单元的表现，使用 agent 等权平均：

$$E_{\text{agent}}^{(r)} = \frac{1}{N} \sum_{i=1}^N e_i^{(r)}.$$

5.3 最差 Agent 误差

为了观察系统短板：

$$E_{\max}^{(r)} = \max_{1 \leq i \leq N} e_i^{(r)}.$$

5.4 Agent 间误差离散度

为了衡量 MAS 是否让不同 agents 的表现更均匀：

$$S_e^{(r)} = \sqrt{\frac{1}{N} \sum_{i=1}^N \left(e_i^{(r)} - E_{\text{agent}}^{(r)} \right)^2}.$$

5.5 通信收益

以第 0 轮本地初始预测为 baseline，定义第 r 轮通信收益：

$$G^{(r)} = E_{\text{weighted}}^{(0)} - E_{\text{weighted}}^{(r)}.$$

若 $G^{(r)} > 0$ ，说明通信后整体局部分类误差下降。

6 实验记录格式

建议每一行记录一个 agent 在一个 run 的一个通信轮数终点上的局部误差：

表 3: 逐 agent 记录表模板

run	N	R	topology	agent	n_i	metrics
001	8	3	one-peer-exp	0	128	$e_i^{(0)}, e_i^{(1)}, e_i^{(2)}, e_i^{(3)}, \Delta e_i$
001	8	3	one-peer-exp	1	128	$e_i^{(0)}, e_i^{(1)}, e_i^{(2)}, e_i^{(3)}, \Delta e_i$

聚合表则以一个 run 为单位：

表 4: 聚合结果表模板

run	seed	N	R	topology	E_{weighted}	$E_{\max}$	S_e
001	42	8	3	mesh	0.128	0.219	0.041
002	42	8	3	one-peer-exp	0.147	0.250	0.052

7 分析与可视化

推荐输出四类图：

- 误差随轮数变化：**横轴为通信轮数 r ，纵轴为 $E_{\text{weighted}}^{(r)}$ ，不同线条表示不同 topology 或不同 N 。
- 规模热力图：**横轴为 N ，纵轴为 R ，颜色为最终误差 $E_{\text{weighted}}^{(R)}$ 。

3. **Agent 间 box plot:** 对每个实验条件绘制 $\{e_i^{(R)}\}_{i=1}^N$, 观察不均衡和 outlier agents。
4. **通信收益曲线:** 绘制 $G^{(r)}$, 判断额外通信轮是否仍有边际收益。

如果需要统计检验, 可以拟合以下回归模型:

$$E_{\text{weighted}}^{(R)} = \beta_0 + \beta_1 \log_2 N + \beta_2 R + \beta_3 \mathbb{I}[\tau = \text{mesh}] + \beta_4 \mathbb{I}[\tau = \text{onepeer}] + \varepsilon.$$

其中 $\beta_2 < 0$ 表示更多通信轮数降低误差, $\beta_1 > 0$ 表示规模增大带来更高协调难度。

8 最终报告结构

最终论文式报告建议采用如下结构:

1. **Problem Setup:** 说明全局数组分类任务、局部 shard、agent 只能访问本地数组。
2. **Local Error Metric:** 给出 $e_i^{(r)}$ 、 $E_{\text{weighted}}^{(r)}$ 、 $E_{\text{max}}^{(r)}$ 的公式。
3. **Experimental Grid:** 报告 $N \in \{2, 4, 8, 16, \dots\}$ 、 $R \in \{2, 3, 5\}$ 、topologies 和 seeds。
4. **Results:** 展示误差曲线、热力图、box plot 和聚合表。
5. **Discussion:** 分析通信是否改善局部分类, 是否存在规模瓶颈, 以及不同 topology 的差异。
6. **Reproducibility:** 记录模型、随机种子、数组生成方式、分类标签生成方式和 trace 保存策略。

9 复现实验的最小伪代码

```
for seed in seeds:
    build global labeled array D
    for N in [2, 4, 8, 16, 32]:
        split D into N local shards
        for topology in topologies:
            initialize MAS agents
            evaluate local errors at round 0
            for r in range(1, R + 1):
                exchange messages under topology
                update each agent's local predictions
                evaluate each local error  $e_i^{(r)}$ 
            aggregate weighted error, max error, variance
```

10 注意事项

- 真实标签只用于 evaluator。若实验要求 blind evaluation, 不要把 y_{ij} 放入 agent prompt。
- 若保存 prompt 和 raw response trace, 需要确认其中没有 API key、私人数据或测试标签。

- 当 n_i 不相等时，主结果优先报告样本加权平均 E_{weighted} ，同时补充 agent 平均 E_{agent} 。
- 若只比较 topology，应固定模型、prompt、temperature、seed、数组生成方式和分类器输出格式。
- 若观察 $R = 2, 3, 5$ ，建议同时保存每一轮的中间误差，而不是只保存最终轮，方便估计通信的边际收益。

11 一句话总结

本实验的核心是把 MAS 的全局协作效果落到每个 agent 自己本地数组上的逐样本分类正确性：先测每个 agent 的局部 error rate，再跨 agents、轮数和规模聚合。这样既能观察整体分类性能，也能看到通信是否真正改善了局部判断，以及大规模 MAS 中哪些 agents 仍然是误差瓶颈。